

Analog Water Meter Reading System Using YOLO with Digit Transition Modeling and Pointer Angle Estimation

ระบบอ่านค่ามิเตอร์น้ำแบบอนาล็อกด้วย YOLO
ร่วมกับโมเดลการเปลี่ยนผ่านตัวเลขและการ
ประมาณมุมเข็ม

Abstract

การอ่านค่ามิเตอร์น้ำแบบอนาล็อกโดยอัตโนมัติ (Automatic Meter Reading: AMR) ยังคงเป็นปัญหาที่ท้าทายเนื่องจากความแปรปรวนของสภาพแวดล้อมจริง ปัญหาการเปลี่ยนค่าก้ำกึ่งของตัวเลข (digit rollover) และการอ่านค่าจากหน้าปัดเข็ม งานวิจัยนี้นำเสนอระบบ AMR แบบครบวงจรที่ผสมผสานการตรวจจับบริเวณที่สนใจด้วย YOLO การรู้จำตัวเลขแบบ digit-wise โดยใช้ Convolutional Neural Network ร่วมกับการจำแนกสถานะ transition และการประมาณมุมเข็มด้วยโมเดล regression สำหรับหน้าปัดอนาล็อก กลไกการจัดการ transition ที่นำเสนอสามารถแก้ปัญหา half-digit rollover ได้อย่างมีประสิทธิภาพผ่านการใช้ตรรกะ carry-over และความต่อเนื่องเชิงลำดับเวลา ผลการทดลองกับภาพมิเตอร์น้ำจากสภาพแวดล้อมจริงแสดงให้เห็นว่าระบบสามารถรู้จำตัวเลขได้ด้วยความแม่นยำประมาณ 95% และโมเดลทำนายมุมเข็มมีค่า Mean Absolute Error ประมาณ $\pm 3^\circ$ หรือคิดเป็นความถูกต้อง 96% ภายในช่วง $\pm 5^\circ$ ระบบที่พัฒนาขึ้นสามารถทำงานได้อย่างเสถียรในสภาพภาคสนามและถูกนำไปใช้งานจริงผ่านแอปพลิเคชันแบบเว็บบนอุปกรณ์พกพา แสดงให้เห็นถึงศักยภาพในการประยุกต์ใช้ในระบบ AMR จริง

Index Terms : Automatic Meter Reading, Analog Water Meter, Digit Rollover, Transition-State Classification, Pointer Angle Regression, YOLO, Deep Learning

1. Introduction

การติดตามปริมาณการใช้น้ำอย่างถูกต้องเป็นหัวใจสำคัญของระบบสาธารณูปโภค ทั้งในด้านการเรียกเก็บค่าน้ำ การวางแผนทรัพยากร และการบริหารจัดการโครงข่ายการแจกจ่ายน้ำ อย่างไรก็ตาม มิเตอร์น้ำส่วนใหญ่ที่ใช้อยู่ในปัจจุบันยังคงเป็นมิเตอร์อนาล็อกแบบเข็มชี้และตัวเลขโรลเลอร์ ซึ่งต้องอาศัยแรงงานคนในการอ่านค่าซ้ำ ๆ ทุกเดือน การเก็บข้อมูลด้วยมือมีข้อจำกัดจากปัจจัยหลายอย่าง

เช่น ความผิดพลาดจากมนุษย์ (human error) คุณภาพของภาพถ่ายที่ไม่สม่ำเสมอ ความสกปรกของกระจกมิเตอร์ การสะท้อนแสง รวมถึงรูปแบบของมิเตอร์ที่แตกต่างกันในแต่ละพื้นที่

Figure 1 ตัวอย่างภาพมิเตอร์น้ำอนาล็อกจากสภาพแวดล้อมจริง



แม้จะมีงานวิจัยด้าน Automatic Meter Reading (AMR) เพิ่มขึ้นมาก แต่ส่วนใหญ่ยังเน้นการอ่านค่าตัวเลข ไม่รองรับ pointer dial และมักทำงานเฉพาะในสภาพควบคุม งานจำนวนมากยังไม่รองรับการใช้งานจริงผ่านโทรศัพท์มือถือซึ่งเป็นอุปกรณ์ที่เจ้าหน้าที่ใช้ในภาคสนาม

งานวิจัยนี้มีเป้าหมายเพื่อพัฒนา AMR (Automatic Meter Reading) ที่ใช้งานได้จริงในสภาพภาคสนามของไทย โดยรองรับทั้งตัวเลขและเข็มชี้ในระบบเดียว Contribution หลักดังนี้

- **YOLO-based Digit and Dial Detector**
พัฒนาโมเดล YOLO ที่รับจูนจากภาพภาคสนามจริง เพื่อเพิ่มความแม่นยำในการตรวจจับบริเวณตัวเลข (digit window) และหน้าปัดเข็ม (pointer dial) แม้ภาพเอียง เบลอ มีฝุ่น หรือมีเงาสะท้อน
- **Digit-wise CNN Recognition Model**
โมเดล CNN แบบแยกตัวเลขรายหลัก ช่วยลดข้อผิดพลาดจาก half-digit transition และ cropping ที่ไม่แม่นยำในงานเดิมที่ใช้ OCR แบบ sequence
- **Transition-State Classification Model (Contribution ใหม่)**
พัฒนาโมเดล Transition Classification เพื่ออ่าน “ตัวเลขที่กำลังเลื่อน” (digit rollover) โดยจำแนกระหว่าง **stable digit** และ **transition digit** เพื่อแก้ปัญหา half-digit transition ซึ่งเป็นข้อจำกัดหลักของ OCR ทั่วไป และทำให้การอ่านค่าต่อเนื่องมีความถูกต้องสูงขึ้น

- **Pointer-Angle Regression Model**
ระบบประเมินมุมชี้ (pointer angle) จากตำแหน่งปลายเข็มที่ตรวจจับด้วย YOLO หรือการแบ่งส่วนภาพ เพื่อรองรับมิเตอร์เข็มที่เป็นส่วนหลักในมิเตอร์น้ำวนาล็อก
- **Low-quality Image Enhancement Preprocessing**
รวมขั้นตอน adaptive threshold, denoise, histogram equalization และ multi-stage cropping เพื่อเพิ่มประสิทธิภาพของผลลัพธ์ในสภาพการถ่ายภาพจริง
- **Field-deployable Mobile AMR System**
พัฒนาแอปมือถือ WebView เชื่อมต่อกับ Django backend ที่รองรับการบันทึกข้อมูลแบบเรียลไทม์ พร้อมระบบล็อกอินและบันทึกประวัติภาคสนาม

2. Related Work and Research Gap

2.1 Summary of Existing Work (งานวิจัยที่เกี่ยวข้อง)

งานวิจัยด้าน Automatic Meter Reading (AMR) ได้มีการพัฒนาอย่างต่อเนื่องทั้งในรูปแบบมิเตอร์ดิจิทัลและมิเตอร์อนาล็อก โดยเทคนิคที่ถูกนำมาใช้ส่วนใหญ่แบ่งออกเป็น 3 กลุ่มหลัก ได้แก่ ระบบประมวลผลภาพแบบดั้งเดิม (Traditional Image Processing), ระบบตรวจจับวัตถุและรู้จำตัวเลขด้วย Deep Learning, และงานที่มุ่งเน้นการอ่านมาตรแบบเข็ม (Pointer Meter Reading)

1) ระบบ AMR บน Edge Device และการอ่านมิเตอร์ดิจิทัล-อนาล็อกแบบผสม

งานของ *Jomjol (2021)* ได้นำเสนอระบบอ่านค่ามิเตอร์บนอุปกรณ์ ESP32-CAM ซึ่งประมวลผลด้วย TensorFlow Lite CNN บนอุปกรณ์ปลายทาง (Edge AI) โดยรองรับทั้งตัวเลขแบบ rolling digit และเข็มอนาล็อก ระบบยังมีการใช้ *Correction Logic* เช่น Carry-over และ Consistency Check เพื่อปรับค่าที่อ่านผิด และรองรับการเชื่อมต่อ MQTT / Home Assistant สำหรับ IoT ได้อย่างมีประสิทธิภาพ อย่างไรก็ตาม ข้อจำกัดของงานคือความละเอียดภาพต่ำของ ESP32-CAM และไม่สามารถใช้โมเดลที่ซับซ้อนมากได้ในสภาพจริง

2) การใช้ YOLO ร่วมกับ CNN เพื่ออ่านมิเตอร์น้ำแบบอนาล็อก

งานของ *Dasgupta et al. (2019)* นำเสนอระบบ AMR โดยใช้ YOLOv2 ตรวจจับตำแหน่ง Digit Box และ Pointer Dial ก่อนส่งให้ CNN Regression ทำนายค่าตัวเลขและตำแหน่งเข็ม ผลลัพธ์แสดงให้เห็นว่าวิธีแบบ Hybrid (Detection + Regression) ให้ผลแม่นยำกว่า OCR แบบดั้งเดิม โดยเฉพาะในภาพที่เบลอหรือมีการเอียงของกล้อง

3) การรู้จำตัวเลขบนมิเตอร์ไฟฟ้าในสภาพจริง

งานของ *Imran et al. (2023)* ศึกษาการอ่านค่ามิเตอร์ไฟฟ้าดิจิทัลและอนาล็อกจากภาพถ่าย โดยใช้ YOLOv3 ตรวจจับบริเวณตัวเลขบนจอแสดงผล และเปรียบเทียบกับวิธี Handcrafted Features บน dataset ขนาดกว่า 12,000 ภาพ ผลลัพธ์แสดงความแม่นยำสูงกว่า 98% แม้ในสภาพแสงที่แปรผันหรือภาพที่เบลอ งานนี้ยืนยันว่า YOLO สามารถทนต่อสภาพภาคสนามได้ดีและเหนือกว่าวิธีคลาสสิกอย่างมาก แต่ยังไม่รองรับกรณี rolling digit หรือ transition digit โดยตรง

4) งานอ่านเข็มมาตรวัดสำหรับอุตสาหกรรมในสภาพแสงและฉากหลังยาก

งานของ *Li et al. (2021)* มุ่งแก้ปัญหาสภาพจริง เช่น แสงไม่สม่ำเสมอหรือหน้าปัดมีฟิล์มสารเคลือบรบกวนการมองเห็น โดยใช้ระบบ multi-step edge detection + Hough Transform ตรวจจับวงกลมหน้าปัดก่อนทำ pointer extraction ผลทดสอบให้ความคลาดเคลื่อนเพียง 0.994% และใช้เวลาประมวลผลรวดเร็ว จึงเหมาะกับงานอุตสาหกรรม แต่ไม่รองรับ rolling digits หรือระบบ AMR เต็มรูปแบบสำหรับมิเตอร์น้ำ

5) งาน pointer-meter reading สมัยใหม่ที่ใช้ Deep Learning แบบเต็มรูปแบบ

งานของ *Li et al. (2025)* ใช้ YOLOX-DC ร่วมกับ PM-SwinUnet สำหรับ pointer segmentation และ Improved Angle Method เพื่ออ่านค่ามาตรเข็มในภาพจริง ผลลัพธ์มี Precision/Recall สูงกว่า 99% และใช้เวลาเฉลี่ยเพียง 0.6 วินาทีต่อการอ่าน ทั้งยังมีความทนทานต่อภาพเอียง สภาพแสงยาก และฉากหลังซับซ้อน แต่ระบบยังรองรับเฉพาะเข็ม ไม่รองรับการอ่านตัวเลขดิจิทัลแบบโรลเลอร์

6) งานอ่านเข็มในสภาพแสงน้อย (Low-light pointer meter reading)

งานของ *Wu et al. (2021)* พัฒนาระบบอ่านเข็มโดยใช้ Mask-RCNN + PrRoI Pooling + ResNet101 Regression พร้อมโมดูลเพิ่มแสงแบบ RBF Fusion เพื่อให้สามารถทำงานได้ในสภาพแสงน้อย ผลลัพธ์มีค่า error ต่ำเพียง 2.217% และแก้ภาพเอียงได้สำเร็จมากกว่า 98.8% แสดงความแข็งแกร่งของ Deep Learning ในงาน pointer reading แต่ยังคงไม่รองรับ rolling digits เช่นเดียวกับงานอื่นๆ ในกลุ่ม pointer-only approach

2.2 Research Gap (ช่องว่างของงานวิจัยเดิม)

แม้ว่างานวิจัยด้านการอ่านค่ามิเตอร์น้ำอัตโนมัติ (AMR) จะมีพัฒนาการอย่างต่อเนื่อง ทั้งในกลุ่มงานประมวลผลภาพแบบดั้งเดิม งานตรวจจับตัวเลขด้วย YOLO และงานอ่านเข็มมาตรวัด

ด้วย Deep Learning แต่จากการวิเคราะห์งานที่เกี่ยวข้อง พบว่า
ยังคงมีช่องว่างสำคัญหลายประการที่ยังไม่ได้รับการแก้ไขอย่างมี
ประสิทธิภาพดังต่อไปนี้

1) งานเดิมรองรับเพียงบางส่วนของมิเตอร์ ไม่สามารถอ่าน “ตัวเลข + เข็ม” ในระบบเดียว

งานตรวจจับตัวเลขจำนวนมากมุ่งเน้นการอ่าน roller digits เท่านั้น
ขณะที่งาน pointer meter reading ส่วนใหญ่รองรับเฉพาะ
gauge อุตสาหกรรม ไม่ใช่มิเตอร์น้ำที่มีโครงสร้างซับซ้อนกว่า
รวมถึงปัญหากระจกขุ่น แสงสะท้อน และ pointer ที่บางมาก
ยังไม่มีงานใดสามารถอ่านตัวเลขและเข็มให้อยู่ใน pipeline
เดียวกันแบบ end-to-end

ซึ่งเป็นความต้องการสำคัญของหน่วยงานประปาในภาคสนามจริง

2) ไม่มีงานใดรองรับปัญหา “digit rollover / half-digit transition” อย่างเป็นระบบ

OCR แบบ sequence และแม้แต่ CNN-based digit recognition
ในงานก่อนหน้า

ยังไม่สามารถอ่านตัวเลขที่กำลังเปลี่ยนได้อย่างถูกต้อง ส่งผลให้เกิด
error ต่อเนื่องในค่ามิเตอร์ (cumulative reading errors)
ลักษณะปัญหา ได้แก่

- ตัวเลขอยู่ระหว่าง 0 \rightarrow 1 หรือ 9 \rightarrow 0
- ตัวเลขทับซ้อนสองค่า
- ตำแหน่ง cropping ไม่ตรงศูนย์
- สภาพแสงและฝุ่นทำให้ตัวเลขอ่านยาก

3) ความท้าทายด้านคุณภาพภาพ (blur, dirt, reflection, occlusion) ยังไม่ได้รับการแก้ไขรูปแบบ

งานส่วนใหญ่ประเมินโมเดลบน dataset ที่มีสภาพภาพถ่าย
ค่อนข้างดี เช่น พื้นหลังนิ่ง แสงคงที่ ไม่มีคราบสกปรก
และกระจกหน้ามิเตอร์ใส แต่ในสภาพจริงของมิเตอร์น้ำภาพมักมี
ความผิดเพี้ยน เช่น ฝุ่นและคราบน้ำ กระจกขุ่นและรอยนิ้ว
แสงสะท้อนสูง มุมถ่ายเอียง และการสั่นของกล้องมือถือ

4) YOLO \rightarrow OCR Pipeline ของงานก่อนหน้ายังมี error cascade สูงมาก

จากงานก่อนหน้านี้นี้ เมื่อ YOLO crop พื้นที่ตัวเลขคลาดเคลื่อนเพียง
เล็กน้อย OCR มักอ่านผิดทั้งหมด ทำให้เกิดการสะสมความ
คลาดเคลื่อนของค่ามิเตอร์ในระยะยาว สาเหตุคือ การอ่านแบบ
sequence OCR ไวต่อ positioning error YOLO ไม่ได้ถูก fine-
tuned กับภาพสกปรกจริงและ ระบบไม่มี sanity check หรือ
multi-stage cropping

5) งาน pointer-reading เดิมยังไม่รองรับ pointer แบบ มิเตอร์น้ำจริง

Pointer ของมิเตอร์น้ำมีลักษณะเฉพาะ เช่น ขนาดเล็กมาก

สีซีด ฉากหลังรก กระจกโค้งมี reflection มีหลายเข็มซ้อนกัน
งาน pointer meter reading เดิม (เช่น pressure gauge) ใช้กับ
สภาพควบคุม และยังไม่สามารถรับมือกับ real-field meter ได้ดี

6) งานส่วนใหญ่ไม่มีระบบที่พร้อมใช้งานจริง (deployable AMR system)

งานวิจัยจำนวนมากเสนอเพียงโมเดลหรือแนวคิดเชิงทฤษฎี แต่ ไม่
พัฒนาเป็นระบบใช้งาน เช่น ไม่มี mobile app , backend , ระบบ
จัดเก็บข้อมูล และ ไม่มีการทดสอบภาคสนามจริง (field
deployment)

2.3 Research Contribution

จากการวิเคราะห์ช่องว่างของงานวิจัยเดิม (Section 2.2) งานวิจัยนี้
นำเสนอชุดนวัตกรรมเพื่อแก้ไขข้อจำกัดสำคัญของระบบ AMR
แบบเดิม โดยมีส่วนหลักๆดังต่อไปนี้

1) ระบบตรวจจับตัวเลขและหน้าปัดเข็มร่วมกันใน Framework เดียว (Unified YOLO-based Detector)

เพื่อแก้ปัญหาที่งานก่อนหน้ารองรับเพียงบางส่วนของมิเตอร์
(เฉพาะตัวเลขหรือเฉพาะเข็ม) งานนี้พัฒนาโมเดล YOLOv8 ที่
ปรับแต่งจากภาพภาคสนามจริง เพื่อให้สามารถตรวจจับ digit
window ตรวจจับ roller digits รายหลัก ตรวจจับ pointer dial
และตำแหน่ง pointer tip ในระบบเดียวกัน ทำให้เป็น AMR
Pipeline แบบครบวงจร (end-to-end) ชุดแรกที่รองรับทั้งตัว
เลขและเข็มของมิเตอร์น้ำอานาล็อกในสภาพจริง

2) โมเดลรู้จำตัวเลขแบบรายหลัก (Digit-wise CNN) เพื่อลด ปัญหา cropping error และ OCR failure

เพื่อตอบโต้ช่องว่างที่ OCR แบบ sequence ล้มเหลวเมื่อ
cropping ไม่แม่นยำ งานนี้จึงพัฒนาโมเดล Digit-wise CNN
Recognition ซึ่งแยกอ่านทีละหลักอย่างเป็นอิสระ
ข้อดี คือทนต่อ cropping error ลดผลกระทบจากมุมเอียงและภาพ
เบลอ และรองรับตัวเลขแดง-ดำปะปน ด้วยวิธีนี้ ความผิดพลาด
แบบ “cascade error” ใน YOLO \rightarrow OCR Pipeline ลดลงอย่าง
มีนัยสำคัญ

3) โมเดล Transition-State Classification เพื่อรองรับ digit rollover (Contribution ใหม่ล่าสุด)

เพื่อตอบโต้ช่องว่างที่ใหญ่ที่สุดในงานเดิม half-digit
transition งานนี้นำเสนอโมเดลเฉพาะทางที่สามารถ
แยกแยะ stable digit และ transition digit ตรวจจับสถานะ
ตัวเลขที่กำลังเปลี่ยนอย่างแม่นยำ และป้องกันข้อผิดพลาดสะสมของ
ค่ามิเตอร์ในระยะยาว เป็นงานที่เสนอ Rollover-aware Digit
Recognition Model สำหรับมิเตอร์น้ำอานาล็อกจริง

4) โมเดลการประมาณมุมเข็ม (Pointer-Angle Regression) ที่ รองรับสภาพแสงและกระจกมิเตอร์จริง

เพื่อแก้ปัญหาความท้าทายของ pointer dial ของมิเตอร์น้ำ (pointer บาง, ซีด, กระจกสะท้อนแสง) งานนี้พัฒนา

- YOLO-based pointer-tip detection
- Regression model สำหรับคำนวณมุมด้วยความแม่นยำ
- ปรับเทียบมุมเป็นค่าปริมาณน้ำด้วย calibration function

ระบบนี้ทำให้สามารถอ่าน pointer ได้เสถียรในสภาพที่งาน pointer gauge เดิมไม่รองรับ

5) Preprocessing Pipeline สำหรับภาพคุณภาพต่ำในภาคสนามจริง

เพื่อแก้ข้อจำกัดด้านคุณภาพภาพที่พบในมิเตอร์น้ำภาคสนาม เช่น ฝุ่น, กระจกขุ่น, แสงสะท้อน, งานนี้นำเสนอ preprocessing ที่ประกอบด้วย

- adaptive thresholding
- denoising
- histogram equalization
- multi-stage cropping
- reflection suppression

การออกแบบนี้ช่วยเพิ่มความเสถียรของ YOLO, CNN และ Regression ในทุกขั้นตอนของ pipeline

6) ระบบ AMR ที่พร้อมใช้งานจริงบนโทรศัพท์มือถือ (Field-deployable Mobile AMR System)

เพื่อตอบโจทย์ข้อจำกัดด้าน deployment งานนี้พัฒนาระบบ AMR เต็มรูปแบบสำหรับผู้ใช้งานภาคสนาม ได้แก่ Mobile WebView Application , Django-based backend, ระบบล็อกอินเจ้าหน้าที่, การประมวลผลภาพแบบ real-time และการบันทึกข้อมูลย้อนหลังในฐานข้อมูล เป็นงานวิจัยที่ไม่เพียงมีผลลัพธ์เชิงโมเดล แต่ยังเป็นระบบใช้งานจริงสำหรับหน่วยงานประปาภาคสนาม

3. Methodology

3.1 System Overview

ระบบอ่านค่ามิเตอร์น้ำอัตโนมัติที่นำเสนอในงานวิจัยนี้ถูกออกแบบในรูปแบบสถาปัตยกรรมหลายโมดูล ดังแสดงใน Figure 2 โดยมีเป้าหมายเพื่อรองรับการใช้งานจริงในสภาพภาคสนามที่มีความหลากหลายของสภาพแวดล้อม ระบบเริ่มต้นจากการรับภาพมิเตอร์น้ำที่ถ่ายด้วยอุปกรณ์พกพา จากนั้นดำเนินการปรับคุณภาพภาพเบื้องต้น (preprocessing) เพื่อเพิ่มความเหมาะสมสำหรับกระบวนการตรวจจับและรู้จำข้อมูลในขั้นตอนถัดไป

ในขั้นตอนถัดมา ระบบใช้โมเดล YOLO สำหรับการตรวจจับบริเวณที่เกี่ยวข้อง (Region of Interest: ROI) ซึ่งประกอบด้วยช่องตัวเลข (digit window) หน้าปัดเข็ม (pointer

dial) และตำแหน่งปลายเข็ม (pointer tip) โดยผลลัพธ์จากการตรวจจับจะถูกส่งไปยังโมดูลการประมวลผลที่ออกแบบแยกตามลักษณะของข้อมูล

ระบบแบ่งกระบวนการประมวลผลออกเป็นสองโมดูลหลัก ได้แก่ (1) Digit Module ซึ่งทำหน้าที่แยกและรู้จำตัวเลขแบบโรลเลอร์ โดยรวมถึงขั้นตอนการตรวจสอบและแก้ไขกรณีตัวเลขอยู่ระหว่างการเปลี่ยนค่า (digit transition) และ (2) Pointer Module ซึ่งทำหน้าที่ประมาณค่ามุมของเข็มจากหน้าปัดนาฬิกา เพื่อนำไปคำนวณค่าปริมาณการใช้น้ำ ทั้งสองโมดูลถูกออกแบบให้สามารถรองรับภาพจากสภาพแวดล้อมจริง เช่น ภาพที่มีความเบลอสองไม่สม่ำเสมอ หรือมีฝุ่นและคราบบนหน้าปัดมิเตอร์

ผลลัพธ์จากทั้งสองโมดูลจะถูกนำเข้าสู่ขั้นตอน Sanity Validation and Fusion เพื่อทำการตรวจสอบความสอดคล้องของข้อมูลและผสานผลลัพธ์จากตัวเลขและเข็มเข้าด้วยกัน ก่อนคำนวณเป็นค่ามิเตอร์สุดท้าย ซึ่งจะถูกแสดงผลผ่านแอปพลิเคชันบนอุปกรณ์พกพา และบันทึกลงระบบ backend สำหรับการจัดเก็บและใช้งานต่อไป




Figure 2 System overview of the proposed analog water meter reading pipeline

3.2 Dataset Collection and Annotation

ชุดข้อมูลที่ใช้ในงานวิจัยนี้ถูกรวบรวมจากภาพมิเตอร์น้ำแบบอนาล็อกในสภาพแวดล้อมจริงภาคสนาม ซึ่งครอบคลุมความหลากหลายของมุมกล้อง, สภาพแสง, และคุณภาพของภาพ รายละเอียดของชุดข้อมูลสรุปไว้ใน Table 1 และตัวอย่างภาพแสดงใน Figure 3

ประเภทชุดข้อมูล	วัตถุประสงค์การใช้งาน	แหล่งที่มา / วิธีสร้างข้อมูล	จำนวนภาพ
ภาพมิเตอร์น้ำโดยรวม	ตรวจจับ ROI ด้วย YOLO (ช่องตัวเลข หน้าปัดเข็ม และ ปลายเข็ม)	ภาพถ่ายจากสภาพแวดล้อมและเพิ่มความหลากหลายด้วยเทคนิค data augmentation	674

ภาพตัวเลข รายการหลัก	การรู้จำตัวเลขด้วย CNN (ตัวเลข 0–9 และคลาส NaN)	ครอบจากบริเวณ digit window	มากกว่า 5,000
ภาพหน้าปัด เข็ม	การประมาณมุมเข็ม (Pointer Angle Regression)	ครอบจากผลลัพธ์การ ตรวจจับของ YOLO	มากกว่า 3,000
ภาพช่วง ตัวเลขกำลัง เลื่อน	การจำแนกสถานะ transition และ carry-over	แยกเฟรมจากวิดีโอช่วง digit rollover	3,312

Table 1 ชุดข้อมูลที่ใช้ในการพัฒนาระบบ



Figure 3 ตัวอย่างภาพมิเตอร์น้ำแบบอนาล็อกที่เก็บจากสภาพแวดล้อมจริงภาคสนาม

3.3 Preprocessing

เนื่องจากภาพมิเตอร์น้ำแบบอนาล็อกที่ถ่ายจากสภาพแวดล้อมจริงมักมีความแปรปรวนสูง ทั้งในด้านสภาพแสง มุมกล้อง ความคมชัด และการสะท้อนจากกระจกหน้าปัด ขั้นตอนการปรับคุณภาพภาพเบื้องต้น (preprocessing) จึงมีบทบาทสำคัญในการเพิ่มความเสถียรและความแม่นยำของกระบวนการตรวจจับและการรู้จำข้อมูลในลำดับถัดไป

ในขั้นตอนแรก ภาพอินพุตทั้งหมดจะถูกปรับขนาดและจัดรูปแบบให้สอดคล้องกับขนาดอินพุตของโมเดลตรวจจับด้วย YOLO เพื่อให้การประมวลผลเป็นไปอย่างมีประสิทธิภาพ จากนั้นจึงดำเนินการปรับปรุงคุณภาพภาพเพื่อลดผลกระทบจากสภาพแสงที่ไม่สม่ำเสมอ โดยใช้เทคนิคการเพิ่มความแตกต่างของภาพ (contrast enhancement) ร่วมกับการปรับฮิสโตแกรมแบบปรับตัว (adaptive histogram equalization) เพื่อช่วยให้รายละเอียดของตัวเลขและเข็มชี้มีความชัดเจนมากขึ้น

นอกจากนี้ ยังมีการลดสัญญาณรบกวน (denoising) เพื่อลดผลกระทบจาก noise ที่เกิดจากการถ่ายภาพในสภาพแสงน้อยหรือการสั่นของกล้อง รวมถึงการจัดการกับภาพที่มีการเอียงหรือหมุนจากมุมกล้องที่ไม่สม่ำเสมอ โดยทำการจัดแนวภาพ (image alignment) ให้สอดคล้องกับภาพอ้างอิง (reference image) เพื่อให้หน้าปัดมิเตอร์อยู่ในทิศทางมาตรฐานเดียวกัน ขั้นตอนนี้ช่วยเพิ่มความแม่นยำในการตรวจจับบริเวณที่สนใจ (ROI) และลดความคลาดเคลื่อนในขั้นตอนการครอบภาพ

หลังจากการตรวจจับ ROI ด้วย YOLO ระบบจะใช้แนวทางการครอบแบบหลายขั้นตอน (multi-stage cropping) เพื่อปรับตำแหน่งและขนาดของภาพครอบให้เหมาะสมยิ่งขึ้น โดยเฉพาะบริเวณช่องตัวเลข ซึ่งความคลาดเคลื่อนเพียงเล็กน้อยอาจส่งผลให้การรู้จำตัวเลขด้วยโมเดล CNN เกิดความผิดพลาดได้ กระบวนการนี้ช่วยให้ภาพตัวเลขอยู่กึ่งกลางและมีสัดส่วนที่สม่ำเสมอ ส่งผลให้การรู้จำตัวเลขรายการหลักมีความเสถียรมากขึ้น

โดยสรุป ขั้นตอน preprocessing ที่ออกแบบในงานวิจัยนี้ มีเป้าหมายเพื่อรองรับภาพจากสภาพแวดล้อมจริงที่มีคุณภาพหลากหลาย และช่วยลดผลกระทบของปัจจัยรบกวนก่อนเข้าสู่กระบวนการตรวจจับและรู้จำข้อมูลด้วยโมเดลเชิงลึกทั้งในส่วนของตัวเลขและหน้าปัดเข็ม



Figure 4 ตัวอย่างการจัดแนวภาพในขั้นตอน preprocessing

ขั้นตอน preprocessing ดังกล่าวช่วยลดความผิดพลาดในการตรวจจับ ROI และเพิ่มความเสถียรของการรู้จำตัวเลขในภาพที่มีคุณภาพต่ำ ซึ่งสะท้อนให้เห็นจากผลการทดลองใน Section 5

3.4 YOLO-Based ROI Detection

ในงานวิจัยนี้ การตรวจจับบริเวณที่สนใจ (Region of Interest: ROI) ถูกดำเนินการโดยใช้โมเดล YOLO ซึ่งถูกปรับแต่งจากภาพมิเตอร์น้ำจริงในภาคสนาม เพื่อรองรับความหลากหลายของรูปแบบมิเตอร์ สภาพแสง และมุมกล้องที่ไม่แน่นอน โมเดล YOLO ทำหน้าที่ตรวจจับ ROI หลักที่จำเป็นต่อการอ่านค่ามิเตอร์น้ำแบบอนาล็อก ได้แก่ บริเวณช่องตัวเลข (digit window) หน้าปัดเข็ม (pointer dial) และตำแหน่งปลายเข็ม (pointer tip)

สำหรับส่วนของอ่านค่าตัวเลข ระบบใช้ผลลัพธ์จาก YOLO ในการระบุตำแหน่งของ digit window ซึ่งครอบคลุมแถบตัวเลขทั้งหมดบนหน้ามิเตอร์ ดังแสดงใน **Figure 5(a)** การตรวจจับในลักษณะนี้ช่วยให้สามารถครอบภาพตัวเลขออกมาได้อย่างแม่นยำและสม่ำเสมอ ลดผลกระทบจากความคลาดเคลื่อนของตำแหน่งหรือการเอียงของภาพ ซึ่งเป็นปัจจัยสำคัญต่อความถูกต้องของการรู้จำตัวเลขในขั้นตอนถัดไป

ในขณะเดียวกัน สำหรับมิเตอร์ที่มีหน้าปัดเข็ม ระบบใช้ YOLO เพื่อตรวจจับบริเวณหน้าปัดเข็มและตำแหน่งปลายเข็มโดยตรง ดังแสดงใน **Figure 5(b)** การระบุ ROI ของหน้าปัดเข็มช่วยจำกัดขอบเขตการประมวลผลให้อยู่เฉพาะบริเวณที่เกี่ยวข้อง ขณะที่การตรวจจับตำแหน่งปลายเข็มทำให้สามารถนำข้อมูลไปใช้ในการคำนวณมุมเข็มได้อย่างมีประสิทธิภาพ แม้ในกรณีที่เข็มมีขนาดเล็ก สีซีด หรือมีการสะท้อนจากกระจกหน้าปัด

การใช้ YOLO เป็นขั้นตอนแรกของการตรวจจับ ROI ช่วยให้ระบบสามารถแยกกระบวนการประมวลผลออกเป็นสองโมดูลหลัก ได้แก่ Digit Module และ Pointer Module ได้อย่างชัดเจน นอกจากนี้ การตรวจจับ ROI ที่แม่นยำยังช่วยลดปัญหา error cascade ที่อาจเกิดขึ้นจากการครอบภาพที่ไม่ตรงตำแหน่ง และเพิ่มความเสถียรของระบบอ่านค่ามิเตอร์น้ำโดยรวมเมื่อใช้งานกับภาพจากสภาพแวดล้อมจริง



(a)

(b)

Figure 5 ตัวอย่างผลลัพธ์การตรวจจับบริเวณที่สนใจ (Region of Interest: ROI) ด้วยโมเดล YOLO บนภาพมิเตอร์น้ำอนาล็อก

(a) การตรวจจับตำแหน่งช่องตัวเลข (digit window)

(b) การตรวจจับบริเวณหน้าปัดเข็มและตำแหน่งปลายเข็ม (pointer dial และ pointer tip)

3.5 Digit Module (CNN + Transition Model)

Digit Module ถูกออกแบบมาเพื่ออ่านค่าตัวเลขจากมิเตอร์น้ำแบบโรลเลอร์ (roller-type digits) ซึ่งเป็นส่วนสำคัญของมิเตอร์น้ำอนาล็อก โมดูลนี้มุ่งเน้นการแก้ปัญหาที่พบได้บ่อยในงานอ่านค่า

มิเตอร์จริง ได้แก่ ความคลาดเคลื่อนจากการครอบภาพ ความไม่สม่ำเสมอของตำแหน่งตัวเลข และกรณีตัวเลขอยู่ระหว่างการเปลี่ยนค่า (digit rollover หรือ half-digit transition)

หลังจากระบบตรวจจับบริเวณช่องตัวเลข (digit window) ด้วย YOLO แล้ว ภาพ ROI ที่ได้จะถูกนำเข้าสู่กระบวนการครอบย่อยออกเป็นตัวเลขรายหลัก (single-digit crops) โดยใช้แนวทาง digit-wise segmentation แทนการรู้จำแบบลำดับ (sequence-based OCR) แนวทางนี้ช่วยลดความไวต่อความคลาดเคลื่อนของตำแหน่งการครอบ ซึ่งเป็นสาเหตุสำคัญของความผิดพลาดในระบบ OCR แบบลำดับ

3.5.1 Digit-wise CNN Recognition

ตัวเลขแต่ละหลักที่ได้จากการครอบจะถูกส่งเข้าสู่โมเดล Convolutional Neural Network (CNN) ซึ่งออกแบบให้มีโครงสร้างแบบ lightweight เพื่อรองรับการประมวลผลที่รวดเร็วและเหมาะสมกับการนำไปใช้งานจริง โมเดล CNN นี้ถูกฝึกให้จำแนกตัวเลข 0–9 รวมถึงคลาสพิเศษ NaN สำหรับกรณีที่ภาพตัวเลขไม่สมบูรณ์หรือไม่สามารถระบุค่าได้อย่างชัดเจน

การรู้จำตัวเลขแบบแยกรายหลักช่วยเพิ่มความยืดหยุ่นให้กับระบบเนื่องจากสามารถประเมินความเชื่อมั่น (confidence) ของตัวเลขแต่ละตำแหน่งได้อย่างอิสระ และลดผลกระทบจากความผิดพลาดเฉพาะจุดโดยไม่กระทบค่าทั้งหมด

3.5.2 Transition-State Classification

แม้วิธี digit-wise CNN จะช่วยลดข้อผิดพลาดได้ในระดับหนึ่ง แต่ในสภาพการใช้งานจริง ตัวเลขบนมิเตอร์น้ำมักอยู่ในสถานะกำลังเลื่อน (digit rollover) ซึ่งทำให้ภาพของตัวเลขแสดงลักษณะก้ำกึ่งระหว่างสองค่า เช่น ตัวเลขหลักถัดไปเริ่มเปลี่ยนค่า ขณะที่หลักก่อนหน้ายังไม่เปลี่ยนสมบูรณ์ เพื่อจัดการกับปัญหานี้ งานวิจัยนี้ได้พัฒนา Transition-State Classification Model ขึ้นโดยเฉพาะ

ในงานวิจัยนี้ การตรวจสอบสถานะของตัวเลขแต่ละหลักจะกระทำหลังจากขั้นตอน digit-wise CNN recognition โดยใช้คุณลักษณะเชิงภาพของตัวเลขที่ครอบแล้ว เช่น ลักษณะการซ้อนทับของตัวเลข ขอบเขตการปรากฏของเส้นตัวเลข และความไม่สมบูรณ์ของรูปทรงตัวอักษร เพื่อจำแนกว่าเป็นตัวเลขที่อยู่ในสถานะคงที่หรืออยู่ระหว่างการเปลี่ยนค่า

โมเดล Transition ทำหน้าที่จำแนกสถานะของตัวเลขแต่ละหลัก ออกเป็นสองกลุ่ม ได้แก่

- (1) **Stable digit** ซึ่งเป็นตัวเลขที่อยู่ในสถานะคงที่ และ
- (2) **Transition digit** ซึ่งเป็นตัวเลขที่อยู่ระหว่างการเปลี่ยนค่า




Figure 6 ตัวอย่างบริเวณช่องตัวเลขของมิเตอร์น้ำแบบโรลเลอร์ในสถานะกำลังเปลี่ยนค่า (digit rollover หรือ half-digit transition) ซึ่งเป็นสาเหตุหลักของความคลาดเคลื่อนในการรู้จำตัวเลขด้วยวิธีทั่วไป

เมื่อระบบตรวจพบว่าเป็น transition digit จะไม่ใช่ค่าที่ได้จาก CNN โดยตรง แต่จะเรียกใช้โมเดล pair + carry-over เพื่อประเมินค่าที่ถูกต้องของตัวเลขในบริบทของตัวเลขข้างเคียง วิธีนี้ช่วยให้ระบบสามารถตีความค่าตัวเลขได้สอดคล้องกับกลไกการทำงานจริงของมิเตอร์น้ำแบบโรลเลอร์

3.5.3 Corrected Digit Output

ผลลัพธ์สุดท้ายจาก Digit Module คือชุดตัวเลขที่ผ่านการแก้ไขแล้ว (Corrected Digits) ซึ่งประกอบด้วยค่าที่ได้จาก CNN สำหรับตัวเลขที่มีสถานะ stable และค่าที่ปรับแก้โดย Transition Model สำหรับตัวเลขที่อยู่ในสถานะ rollover ชุดตัวเลขนี้จะถูกส่งต่อไปยังขั้นตอน Sanity Validation and Fusion เพื่อรวมเข้ากับค่าที่ได้จาก Pointer Module และคำนวณเป็นค่ามิเตอร์สุดท้าย

โดยรวมแล้ว Digit Module ที่นำเสนอสามารถลดข้อผิดพลาดจาก half-digit transition ได้อย่างมีประสิทธิภาพ และเพิ่มความต่อเนื่องของค่าที่อ่านได้เมื่อใช้งานกับภาพจากสภาพแวดล้อมจริง ซึ่งเป็นข้อจำกัดสำคัญของงาน AMR แบบดั้งเดิม

3.6 Pointer Module (Pointer Angle Regression)

Pointer Module ถูกออกแบบมาเพื่ออ่านค่าจากมิเตอร์น้ำแบบเข็มชี้ (pointer dial) ซึ่งยังคงถูกใช้อย่างแพร่หลายในมิเตอร์น้ำอนาล็อก โดยเฉพาะในพื้นที่ภาคสนามที่มิเตอร์แบบดิจิทัลยังไม่ถูกติดตั้งอย่างทั่วถึง การอ่านค่าจากเข็มชี้มีความท้าทายเนื่องจากลักษณะของเข็มที่มีขนาดเล็ก สีซีด และมักถูกครอบด้วยกระจกโค้งที่ก่อให้เกิดแสงสะท้อนและความบิดเบือนของภาพ

หลังจากขั้นตอน YOLO-Based ROI Detection ระบบจะได้รับตำแหน่งของบริเวณหน้าปัดเข็ม (pointer dial) และตำแหน่งปลายเข็ม (pointer tip) ซึ่งถูกนำมาใช้เป็นข้อมูลตั้งต้นสำหรับการประมวลผลใน Pointer Module โมดูลนี้มีวัตถุประสงค์หลักเพื่อประมาณมุมของเข็มชี้และแปลงค่าเชิงเรขาคณิตดังกล่าวให้เป็นค่าปริมาณการใช้น้ำตามสเกลของมิเตอร์

3.6.1 Dial Center Localization

ขั้นตอนแรกของ Pointer Module คือการระบุตำแหน่งศูนย์กลางของหน้าปัดเข็ม โดยระบบใช้ข้อมูล ROI ของ pointer dial ที่ได้จาก YOLO เพื่อจำกัดขอบเขตการค้นหา จากนั้นจึงประเมินตำแหน่งศูนย์กลางของหน้าปัดด้วยวิธีการเชิงเรขาคณิต เช่น การประมาณวงกลมของหน้าปัด หรือการคำนวณตำแหน่งกึ่งกลางของพื้นที่ที่ตรวจจับได้ ขั้นตอนนี้ช่วยลดผลกระทบจากฉากหลังที่ไม่เกี่ยวข้อง และเพิ่มความแม่นยำในการคำนวณมุมของเข็มในขั้นตอนถัดไป

3.6.2 Pointer Tip Extraction

เมื่อได้ตำแหน่งศูนย์กลางของหน้าปัดแล้ว ระบบจะดำเนินการระบุตำแหน่งปลายเข็ม (pointer tip) ซึ่งเป็นจุดสำคัญสำหรับการคำนวณมุมเข็ม ในงานวิจัยนี้ ตำแหน่งปลายเข็มถูกกำหนดจากผลลัพธ์ของการตรวจจับด้วย YOLO หรือจากการประมวลผลภาพเพิ่มเติมภายใน ROI เพื่อจัดการกับกรณีที่มีเข็มสีจางหรือถูกแสงสะท้อนรบกวน การใช้ตำแหน่งปลายเข็มโดยตรงช่วยลดความคลาดเคลื่อนที่อาจเกิดจากการประมาณแนวเส้นเข็มทั้งเส้น



Figure 7 ตัวอย่างภาพหน้าปัดเข็มจากชุดข้อมูลที่ใช้ในการฝึกและประเมินโมเดล Pointer Angle Regression ซึ่งครอบคลุมมุมเข็มและสภาพแวดล้อมการถ่ายภาพที่หลากหลาย

3.6.3 Pointer Angle Regression




Figure 8 ตัวอย่างการคำนวณมุมเข็มจากตำแหน่งศูนย์กลางหน้าปัดและตำแหน่งปลายเข็ม ซึ่งใช้เป็นอินพุตสำหรับโมเดล Pointer Angle Regression^{SS}

หลังจากได้ตำแหน่งศูนย์กลางหน้าปัดและตำแหน่งปลายเข็มแล้ว ระบบจะคำนวณมุมของเข็มขึ้นโดยอาศัยความสัมพันธ์เชิงเรขาคณิตระหว่างจุดทั้งสอง มุมเข็มถูกคำนวณในรูปขององศาเชิงขั้ว (polar angle) โดยอ้างอิงกับแกนอ้างอิงที่กำหนดไว้ล่วงหน้า จากนั้นค่ามุมที่ได้จะถูกนำเข้าสู่โมเดล Pointer Angle Regression ซึ่งถูกออกแบบมาเพื่อปรับแก้ความคลาดเคลื่อนที่เกิดจากการบิดเบือนของภาพ มุมกลิ้ง และลักษณะเฉพาะของมิเตอร์แต่ละรุ่น

โมเดล regression ดังกล่าวช่วยให้ระบบสามารถประมาณค่ามุมเข็มได้อย่างเสถียร แม้ในกรณีที่เข็มมีลักษณะบาง ไม่ชัดเจน หรือมีการสะท้อนจากกระจกหน้าปัด ซึ่งเป็นข้อจำกัดสำคัญของวิธีการอ่านเข็มแบบดั้งเดิม

3.6.4 Pointer Value Mapping

มุมเข็มที่ผ่านการประมวลผลจะถูกแปลงเป็นค่าปริมาณการใช้น้ำ โดยอาศัยความสัมพันธ์ระหว่างมุมและสเกลของมิเตอร์น้ำแต่ละรุ่น ซึ่งถูกกำหนดในรูปของฟังก์ชันการแมป (calibration curve) ขั้นตอนนี้ช่วยให้ระบบสามารถรองรับมิเตอร์ที่มีช่วงมุมและสเกลแตกต่างกันได้ โดยไม่จำเป็นต้องปรับเปลี่ยนโครงสร้างของโมเดลหลัก

โดยรวมแล้ว Pointer Module ที่นำเสนอสามารถอ่านค่าจากมิเตอร์น้ำแบบเข็มได้อย่างมีประสิทธิภาพ และทำงานร่วมกับ Digit Module เพื่อรองรับมิเตอร์น้ำอนาล็อกที่มีทั้งตัวเลขแบบโรลเลอร์และหน้าปัดเข็มในระบบเดียว ซึ่งเป็นจุดเด่นสำคัญของงานวิจัยนี้ เมื่อเทียบกับระบบ AMR แบบเดิม

3.7 Sanity Validation and Fusion (Revised)

หลังจากระบบได้รับผลลัพธ์จาก Digit Module และ Pointer Module แล้ว ขั้นตอนสุดท้ายของกระบวนการประมวลผลคือ **Sanity Validation and Fusion** ซึ่งมีบทบาทสำคัญในการตรวจสอบความสมเหตุสมผลเชิงตรรกะ (logical consistency) ของผลลัพธ์ และผสานข้อมูลจากทั้งสองโมดูลให้เป็นค่าการอ่านมิเตอร์น้ำสุดท้ายที่มีความน่าเชื่อถือสูง

เนื่องจากมิเตอร์น้ำแบบอนาล็อกประกอบด้วยทั้งตัวเลขแบบโรลเลอร์และหน้าปัดเข็ม ซึ่งมีความสัมพันธ์กันตามกลไกทางกายภาพของการทำงานจริง การประเมินผลจากแต่ละโมดูลโดยอิสระอาจก่อให้เกิดความไม่สอดคล้องกันในบางกรณี เช่น ตัวเลขอยู่ในช่วงกำลังเปลี่ยนค่า (digit rollover) ขณะที่ตำแหน่งเข็มแสดงค่าใกล้จุดเปลี่ยนสเกล หรือเกิดความคลาดเคลื่อนจากสภาพการถ่ายภาพในภาคสนาม ขั้นตอนที่ **Sanity Validation** จึงถูกออกแบบมาเพื่อตรวจจับและจัดการกับสถานการณ์เหล่านี้อย่างเป็นระบบ

ในขั้นตอนนี้ ระบบจะทำการตรวจสอบผลลัพธ์ในสามมิติหลัก ได้แก่

- (1) **ความถูกต้องของลำดับตัวเลข** โดยตรวจสอบว่าค่าตัวเลขที่อ่านได้เรียงตามหลักตำแหน่งอย่างสมเหตุสมผล และไม่ขัดกับรูปแบบการทำงานของมิเตอร์แบบโรลเลอร์
- (2) **ความต่อเนื่องของค่าการอ่าน** โดยเปรียบเทียบค่าที่อ่านได้กับค่าก่อนหน้าที่ถูกบันทึกไว้ เพื่อป้องกันกรณีค่ากระโดดผิดปกติที่ไม่สอดคล้องกับการใช้งานน้ำจริง และ
- (3) **ความสอดคล้องระหว่างตัวเลขและเข็ม** โดยพิจารณาความสัมพันธ์ระหว่างค่าทศนิยมจาก Pointer Module กับหลักตัวเลขที่อยู่ติดกัน หากพบความขัดแย้ง ระบบจะเลือกใช้ผลลัพธ์จากโมดูลที่มีความเชื่อมั่นสูงกว่า หรือใช้กฎการ carry-over เพื่อรักษาความต่อเนื่องของค่า

หลังจากผ่านกระบวนการตรวจสอบความถูกต้องแล้ว ขั้นตอนที่ **Fusion** จะทำการรวมค่าที่ผ่านการตรวจสอบจาก Digit Module และ Pointer Module เข้าด้วยกัน เพื่อคำนวณเป็นค่าการใช้น้ำสุดท้ายในรูปแบบเชิงปริมาณที่สอดคล้องกับหน่วยและสเกลของมิเตอร์น้ำจริง ขั้นตอนนี้ช่วยให้ระบบสามารถรองรับมิเตอร์น้ำแบบอนาล็อกที่มีทั้งตัวเลขแบบโรลเลอร์และหน้าปัดเข็มในระบบเดียวกันได้อย่างมีประสิทธิภาพ

ผลลัพธ์สุดท้ายที่ได้จากขั้นตอน Sanity Validation and Fusion จะถูกส่งออกไปแสดงผลบนแอปพลิเคชันบนอุปกรณ์พกพา และจัดเก็บผ่าน backend service เพื่อรองรับการเรียกดูย้อนหลัง การ

ตรวจสอบภายหลัง และการประยุกต์ใช้งานในระบบบริหารจัดการ
น้ำในระดับภาคสนาม

โดยสรุป ขั้นตอน Sanity Validation and Fusion มีบทบาทสำคัญ
ในการเพิ่มความน่าเชื่อถือของระบบอ่านค่ามิเตอร์น้ำอัตโนมัติ ลด
ผลกระทบจากความคลาดเคลื่อนของโมเดลย่อย และทำให้ผลลัพธ์
สุดท้ายมีความสอดคล้องกับการทำงานจริงของมิเตอร์น้ำแบบ
อนาล็อกในสภาพแวดล้อมภาคสนาม

4. Experimental Setup

ในส่วนนี้จะอธิบายรายละเอียดของสภาพแวดล้อมการทดลอง ชุด
ข้อมูลที่ใช้ การตั้งค่าการฝึกโมเดล และเกณฑ์การประเมินผล เพื่อ
แสดงให้เห็นถึงความถูกต้องและความเป็นธรรมของการทดลองที่ใช้
ในการประเมินประสิทธิภาพของระบบอ่านค่ามิเตอร์น้ำแบบ
อนาล็อกที่นำเสนอ

4.1 Experimental Environment

การทดลองทั้งหมดดำเนินการบนเครื่องคอมพิวเตอร์ที่รองรับการ
ประมวลผลด้วยกราฟิกการ์ด (GPU) เพื่อให้เหมาะสมกับการฝึกและ
ทดสอบโมเดลเชิงลึกที่ใช้ในงานวิจัยนี้ ระบบถูกพัฒนาด้วยภาษา
Python และใช้ไลบรารีมาตรฐานด้านการประมวลผลภาพและการ
เรียนรู้เชิงลึก เช่น OpenCV และเฟรมเวิร์ก deep learning ที่นิยม
ใช้งานในงานด้าน Computer Vision

สถาปัตยกรรมของระบบถูกออกแบบในลักษณะ modular ซึ่งช่วย
ให้สามารถฝึกและประเมินผลแต่ละโมดูลแยกจากกันได้อย่างอิสระ
ได้แก่ YOLO-Based ROI Detection, Digit Module, Transition-
State Classification และ Pointer Angle Regression ทั้งนี้
เพื่อให้การวิเคราะห์ผลการทดลองมีความชัดเจนและสามารถระบุ
ผลกระทบของแต่ละส่วนประกอบได้อย่างเป็นระบบ

4.2 Dataset Split and Preparation

ชุดข้อมูลที่ใช้ในการทดลองประกอบด้วยภาพมิเตอร์น้ำแบบ
อนาล็อกที่เก็บจากสภาพแวดล้อมจริงภาคสนาม ซึ่งมีความ
หลากหลายทั้งในด้านมุมมอง สภาพแสง ความคมชัด การสะท้อน
จากกระจก และระดับการสึกหรอของหน้าปัด เพื่อสะท้อนเงื่อนไข
การใช้งานจริงของระบบ Automatic Meter Reading (AMR)

เพื่อให้การประเมินผลมีความน่าเชื่อถือและหลีกเลี่ยงปัญหา *data
leakage* ชุดข้อมูลทั้งหมดถูกแบ่งออกเป็น ชุดฝึก (training set),
ชุดตรวจสอบ (validation set) และ ชุดทดสอบ (test set) ใน

อัตราส่วน 70:15:15 โดยกำหนดให้ไม่มีการทับซ้อนของภาพหรือ
เฟรมจากมิเตอร์เดียวกันระหว่างแต่ละชุดข้อมูล

การแบ่งข้อมูลดำเนินการแยกตามระดับของโมดูลที่ใช้งานในระบบ
ดังนี้

- **ชุดข้อมูลภาพมิเตอร์น้ำโดยรวม**
ใช้สำหรับฝึกและประเมินโมเดล YOLO-Based ROI
Detection ในการตรวจจับบริเวณที่เกี่ยวข้อง ได้แก่ ช่อง
ตัวเลข (digit window), หน้าปัดเข็ม (pointer dial) และ
ตำแหน่งปลายเข็ม (pointer tip)
- **ชุดข้อมูลตัวเลขรายหลัก (digit-wise dataset)**
ใช้สำหรับฝึกโมเดล CNN ในการรู้จำตัวเลข 0–9 และ
คลาส NaN โดยตัดภาพเป็นตัวเลขรายหลักจากผลการ
ตรวจจับของ YOLO และทำการแบ่งชุดข้อมูลตามสัดส่วน
เดียวกัน
- **ชุดข้อมูลหน้าปัดเข็ม (pointer dial dataset)**
ใช้สำหรับฝึกและประเมินโมเดล Pointer Angle
Regression โดยกำหนดค่า ground truth ของมุมเข็มใน
รูปฟังก์ชันตรีโกณมิติ ($\sin\theta$, $\cos\theta$)
- **ชุดข้อมูลช่วงตัวเลขกำลังเลื่อน (digit rollover
dataset)**
ใช้สำหรับฝึกโมเดล Transition-State Classification
และกลไก pair + carry-over ซึ่งถูกจัดเตรียมในลักษณะ
ลำดับภาพ (sequence) เพื่อสะท้อนพฤติกรรม
เปลี่ยนค่าจริงของมิเตอร์น้ำ

การออกแบบกลยุทธ์การแบ่งข้อมูลในลักษณะนี้ช่วยให้แต่ละโมเดล
ถูกประเมินบนข้อมูลที่ไม่เคยเห็นมาก่อนอย่างแท้จริง และเพิ่มความ
น่าเชื่อถือของผลการทดลองทั้งในระดับโมดูลย่อยและระดับระบบ
โดยรวม

4.3 Training Configuration

การฝึกโมเดลในแต่ละโมดูลดำเนินการแยกจากกันตามลักษณะของ
ปัญหา โดยใช้การตั้งค่าการฝึกที่เหมาะสมกับงานจำแนกประเภท
(classification) และงานประมาณค่าเชิงต่อเนื่อง (regression)

สำหรับ YOLO-Based ROI Detection โมเดลถูกฝึกให้สามารถ
ตรวจจับบริเวณที่เกี่ยวข้องบนภาพมิเตอร์น้ำโดยตรงจากภาพอินพุต
ขณะที่ Digit Module และ Transition-State Classification ใช้
การฝึกแบบ supervised learning จากภาพที่ผ่านการครอปและ
ติดป้ายกำกับไว้ล่วงหน้า

ในส่วนของ Pointer Angle Regression โมเดลถูกฝึกให้เรียนรู้ความสัมพันธ์ระหว่างตำแหน่งศูนย์กลางหน้าปัด ตำแหน่งปลายเข็ม และค่ามุมเข็มที่แท้จริง เพื่อรองรับความแปรปรวนของภาพจากมุมกล้องและการบิดเบือนจากกระจกหน้าปัด

การตั้งค่าพารามิเตอร์การฝึก เช่น batch size จำนวน epoch และ learning rate ถูกเลือกโดยพิจารณาจากความเสถียรของการเรียนรู้และความเหมาะสมต่อการนำไปใช้งานจริงในระบบภาคสนาม

4.4 Evaluation Metrics

การประเมินผลของระบบดำเนินการในหลายระดับ (multi-level evaluation) เพื่อสะท้อนทั้งประสิทธิภาพของแต่ละโมดูลย่อยและประสิทธิภาพของระบบอ่านค่ามิเตอร์น้ำโดยรวม เกณฑ์การประเมินถูกเลือกให้เหมาะสมกับลักษณะของงานในแต่ละขั้นตอน ดังนี้

- YOLO-Based ROI Detection

ประเมินประสิทธิภาพของโมเดล YOLO สำหรับการตรวจจับบริเวณที่เกี่ยวข้อง (Region of Interest: ROI) ได้แก่ ช่องตัวเลข (digit window), หน้าปัดเข็ม (pointer dial) และตำแหน่งปลายเข็ม (pointer tip) โดยใช้ค่า Precision และ Recall เพื่อวัดความถูกต้องและความครอบคลุมของการตรวจจับ ซึ่งคำนวณได้จาก

$$Precision = \frac{TP}{TP + FP}$$

$$Recall = \frac{TP}{TP + FN}$$

โดยที่

TP (True Positive) คือกรอบที่ตรวจจับถูกต้อง

FP (False Positive) คือกรอบที่ตรวจจับเกิน

FN (False Negative) คือกรอบที่ตรวจจับพลาด

นอกจากนี้ ยังใช้ค่า mAP (mean Average Precision) เพื่อวัดประสิทธิภาพโดยรวมของการตรวจจับในทุกคลาส ซึ่งเป็นตัวชี้วัดมาตรฐานสำหรับงาน Object Detection ที่มีหลายวัตถุในภาพเดียว

- Digit Recognition

การประเมินโมเดลรู้จำตัวเลขดำเนินการในระดับ digit-wise accuracy เพื่อวัดความถูกต้องของการจำแนกตัวเลขในแต่ละหลัก และในระดับ overall reading accuracy พิจารณาจากการที่ตัวเลขทุกหลักตรงกับค่า

จริงทั้งหมด โดยค่าความแม่นยำ (Accuracy) คำนวณได้จาก

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

การประเมินในสองระดับนี้ช่วยให้สามารถแยกวิเคราะห์ข้อผิดพลาดเฉพาะตำแหน่งออกจากความผิดพลาดของค่ามิเตอร์ทั้งชุดได้อย่างชัดเจน

- Transition Handling

การประเมินส่วนการจัดการตัวเลขกำลังเปลี่ยน (digit rollover เช่น 9→0) ใช้ตัวชี้วัด Transition

Accuracy ซึ่งพิจารณาเฉพาะภาพที่ตัวเลขอยู่ในสถานะ transition โดยคำนวณจาก

Transition Accuracy

$$= \frac{\text{Correct Transition Predictions}}{\text{total Transition samples}}$$

ตัวชี้วัดนี้มีความสำคัญอย่างยิ่ง เนื่องจากช่วง transition เป็นจุดที่ระบบอ่านค่ามิเตอร์แบบดั้งเดิมมักเกิดความผิดพลาดสูง และเป็นเป้าหมายหลักของโมดูล Transition-State Classification ที่นำเสนอในงานวิจัยนี้

- Pointer Angle Regression

การประเมินโมเดลทำนายมุมเข็มใช้ค่า Mean Absolute Error (MAE) เพื่อวัดความคลาดเคลื่อนเชิงมุมระหว่างค่าที่โมเดลทำนายได้และค่าจริง โดยคำนวณจาก

$$MAE = \frac{1}{N} \sum_{i=1}^N |\theta_i - \hat{\theta}_i|$$

θ_i คือมุมจริงของเข็ม

$\hat{\theta}_i$ คือมุมที่โมเดลทำนายได้

ค่า MAE สะท้อนความแม่นยำเชิงปริมาณของการประมาณมุม ซึ่งมีผลโดยตรงต่อการแปลงค่ามุมเป็นค่าปริมาณการใช้น้ำ

- System-Level Evaluation

การประเมินในระดับระบบ (system-level evaluation) ใช้ตัวชี้วัด Final Meter Reading Accuracy ซึ่งนิยามว่าสัดส่วนของภาพที่ระบบสามารถอ่านค่ามิเตอร์สุดท้ายได้ตรงกับค่าจริงครบทุกหลัก รวมทั้งส่วนทศนิยม

โดยคำนวณจาก

$$\text{Final Accuracy} = \frac{\text{Correct Final Readings}}{\text{Total Samples}}$$

ตัวชี้วัดนี้สะท้อนประสิทธิภาพแบบ **end-to-end** ของระบบทั้งหมด หลังจากการผสานผลลัพธ์จาก Digit Module และ Pointer Module ผ่านขั้นตอน Sanity Validation and Fusion ซึ่งเป็นเกณฑ์สำคัญในการประเมินความพร้อมของระบบสำหรับการใช้งานจริงในภาคสนาม

การใช้เกณฑ์การประเมินหลายระดับช่วยให้สามารถวิเคราะห์จุดแข็งข้อจำกัด และผลกระทบของแต่ละโมดูลต่อประสิทธิภาพของระบบอ่านค่ามิเตอร์น้ำอัตโนมัติโดยรวมได้อย่างเป็นระบบ และสนับสนุนการอภิปรายผลใน Section 5 อย่างชัดเจน

4.5 Implementation and Deployment Setup

นอกเหนือจากการทดลองในเชิงโมเดล ระบบที่นำเสนอยังถูกพัฒนาในรูปแบบที่สามารถนำไปใช้งานจริงได้ โดยเชื่อมต่อระหว่างแอปพลิเคชันฝั่งผู้ใช้และระบบประมวลผลฝั่งเซิร์ฟเวอร์

ระบบ backend ถูกพัฒนาด้วย Django framework เพื่อรองรับการอัปโหลดภาพ การประมวลผลอัตโนมัติ และการจัดเก็บผลลัพธ์ ขณะที่ฝั่งผู้ใช้ถูกออกแบบในรูปแบบ Mobile WebView เพื่อให้เจ้าหน้าที่สามารถถ่ายภาพมิเตอร์น้ำ ตรวจสอบผลลัพธ์ และบันทึกข้อมูลภาคสนามได้แบบเรียลไทม์

การทดสอบระบบในลักษณะนี้ช่วยยืนยันว่าระบบ AMR ที่นำเสนอไม่เพียงแต่มีประสิทธิภาพในเชิงอัลกอริทึมเท่านั้น แต่ยังสามารถนำไปใช้งานได้จริงในบริบทของการสำรวจมิเตอร์น้ำภาคสนาม

5. Results

ในส่วนนี้นำเสนอผลการประเมินประสิทธิภาพของระบบอ่านค่ามิเตอร์น้ำแบบอนาล็อกที่นำเสนอ โดยผลลัพธ์ถูกวิเคราะห์ในหลายระดับ ตั้งแต่ประสิทธิภาพของแต่ละโมดูลย่อย ไปจนถึงผลลัพธ์เชิงระบบแบบ end-to-end

5.1 YOLO-Based ROI Detection Performance (Multi-class)

ประสิทธิภาพของโมเดล YOLO สำหรับการตรวจจับบริเวณที่เกี่ยวข้อง (ROI) ได้แก่ ช่องตัวเลข (digit window) หน้าปัดเข็ม

(pointer dial) และตำแหน่งปลายเข็ม (pointer tip) ถูกประเมินจากค่า precision, recall และ mean Average Precision (mAP)

ผลการฝึกโมเดลแสดงให้เห็นว่า loss ในทุกองค์ประกอบ ได้แก่ box loss, classification loss และ distribution focal loss ลดลงอย่างต่อเนื่องทั้งในชุดฝึกและชุดทดสอบ ขณะที่ค่า precision และ recall เพิ่มขึ้นจนเข้าสู่สภาวะคงที่ ดังแสดงใน *Figure 9*




Figure 9 ผลการฝึกโมเดล YOLO สำหรับการตรวจจับบริเวณที่เกี่ยวข้อง (ROI) ของมิเตอร์น้ำ โดยแสดงการเปลี่ยนแปลงของค่า train/validation loss รวมถึงค่า precision, recall และ mAP

นอกจากนี้ ค่า mAP@0.5 และ mAP@0.5:0.95 ซึ่งเป็นตัวชี้วัดมาตรฐานสำหรับงาน object detection มีแนวโน้มเพิ่มขึ้นอย่างสม่ำเสมอ สะท้อนถึงความสามารถของโมเดลในการตรวจจับ ROI ได้อย่างแม่นยำและมีเสถียรภาพ โดยไม่พบสัญญาณของ overfitting

ผลลัพธ์ดังกล่าวยืนยันว่าโมเดล YOLO ที่นำเสนอมีประสิทธิภาพเพียงพอสำหรับการใช้งานในสภาพแวดล้อมจริง และเป็นพื้นฐานสำคัญสำหรับขั้นตอนการรู้จำตัวเลขและการอ่านค่าหน้าปัดเข็มในลำดับถัดไป

5.2 YOLO-Based Digital Window Detection Performance (single-class)

เพื่อเพิ่มความแม่นยำในการตรวจจับบริเวณช่องตัวเลข ระบบได้ฝึกโมเดล YOLOv8 แยกต่างหากสำหรับงานตรวจจับช่องตัวเลขดิจิทัลแบบคลาสเดียว (single-class detection) โดยกำหนดคลาส digital

ผลการฝึกโมเดลแสดงให้เห็นว่า loss ทุกองค์ประกอบ ได้แก่ box loss, classification loss และ distribution focal loss ลดลง

อย่างรวดเร็วในช่วงต้นของการฝึก และค่อย ๆ เข้าสู่สภาวะคงที่ทั้งในชุดฝึกและชุดทดสอบ ดังแสดงใน *Figure 10*




Figure 10 ผลการฝึกและประเมินผลของโมเดล YOLOv8 สำหรับการตรวจจับช่องตัวเลขดิจิทัล (single-class) แสดง training curves ของ loss, precision, recall และ mA

ขณะเดียวกัน ค่า precision และ recall เพิ่มขึ้นจนใกล้ 1.0 ภายในจำนวน epoch ไม่มากนัก สะท้อนถึงความสามารถของโมเดลในการตรวจจับช่องตัวเลขได้อย่างแม่นยำและสม่ำเสมอ นอกจากนี้ ค่า mAP@0.5 และ mAP@0.5:0.95 ที่อยู่ในระดับสูงแสดงให้เห็นว่าโมเดลมีประสิทธิภาพเพียงพอสำหรับการใช้งานจริง

การแยกโมเดล YOLO สำหรับงานตรวจจับช่องตัวเลขโดยเฉพาะช่วยลดความซับซ้อนของปัญหา และเพิ่มความเสถียรของตำแหน่ง ROI ที่ถูกส่งต่อไปยัง Digit Module ซึ่งมีผลโดยตรงต่อความแม่นยำของการรู้จำตัวเลขในขั้นตอนถัดไป

เมื่อเปรียบเทียบกับ การตรวจจับแบบหลายคลาส การฝึกโมเดลแบบ single-class ช่วยลดความซับซ้อนของปัญหาและเพิ่มความเสถียรของตำแหน่ง ROI สำหรับช่องตัวเลขโดยเฉพาะ

5.3 Digit Recognition Performance

การประเมินประสิทธิภาพของโมเดลรู้จำตัวเลข (Digit Module) ดำเนินการในระดับ **digit-wise recognition** โดยพิจารณาความสามารถของโมเดล Convolutional Neural Network (CNN) ในการจำแนกตัวเลขหลัก (0–9) รวมถึงคลาสพิเศษ *NaN* ซึ่งใช้แทนกรณีตัวเลขไม่สมบูรณ์หรือไม่สามารถระบุค่าได้อย่างชัดเจนในสภาพการใช้งานจริงของมิเตอร์น้ำแบบโรลเลอร์

โมเดล CNN ถูกฝึกด้วยชุดข้อมูลภาพตัวเลขเดี่ยว (single-digit crops) ขนาด 32×20 พิกเซล จำนวนมากกว่า 5,000 ภาพ โดยใช้ฟังก์ชันสูญเสียแบบ *Categorical Cross-Entropy* และตัวปรับค่าพารามิเตอร์แบบ *Adam* กำหนดค่า batch size เท่ากับ 4 และจำนวน epochs เท่ากับ 100

ผลการฝึกโมเดลแสดงให้เห็นว่า accuracy ของชุดข้อมูลฝึกและชุดข้อมูลตรวจสอบเพิ่มขึ้นอย่างรวดเร็วในช่วงต้นของการฝึก และคงที่ในระดับสูงเมื่อสิ้นสุดกระบวนการ ขณะที่ค่า loss ลดลงอย่างต่อเนื่องและมีแนวโน้มเสถียรในช่วงท้าย *Figure 11(a)* ซึ่งสะท้อนถึงความสามารถของโมเดลในการเรียนรู้รูปแบบของตัวเลขได้อย่างมีประสิทธิภาพ และสามารถ generalize ไปยังข้อมูลที่ไม่เคยเห็นมาก่อนได้โดยไม่เกิดปัญหา overfitting

เมื่อประเมินผลบนชุดข้อมูลทดสอบ โมเดลสามารถจำแนกตัวเลขได้ด้วยค่า Accuracy เฉลี่ยประมาณ 95% และมีค่า F1-score สูงกว่า 0.9 แสดงถึงสมดุลที่ดีระหว่าง precision และ recall ในการจำแนกตัวเลขแต่ละคลาส ผลการเปรียบเทียบค่าตัวเลขจริงกับค่าที่โมเดลทำนายได้ *Figure 11(b)* แสดงให้เห็นว่าโมเดลสามารถทำนายค่าตัวเลขได้ใกล้เคียงค่าจริงในภาพส่วนใหญ่

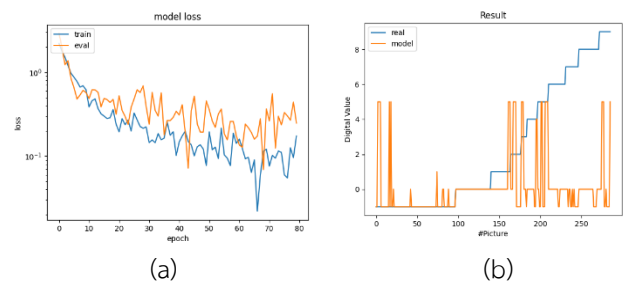


Figure 11 Performance of the digit-wise CNN model

(a) กราฟ Training and validation loss of the digit-wise CNN model

(b) Comparison between ground-truth digits and CNN predictions on S

อย่างไรก็ตาม ความคลาดเคลื่อนที่พบยังคงเกิดขึ้นในกรณีที่ตัวเลขอยู่ในสภาวะก้ำกึ่งระหว่างการเปลี่ยนค่า (digit rollover) หรือในกรณีที่ตัวเลขมีลักษณะใกล้เคียงกัน ซึ่งเป็นข้อจำกัดโดยธรรมชาติของการรู้จำตัวเลขจากมิเตอร์น้ำแบบโรลเลอร์

ผลลัพธ์ดังกล่าวสนับสนุนแนวทางการออกแบบระบบแบบ **digit-wise recognition** ร่วมกับ **Transition-State Classification** เพื่อจัดการกับข้อผิดพลาดเฉพาะตำแหน่งโดยไม่กระทบต่อค่าตัวเลขทั้งชุด

โดยสรุป โมเดล CNN สำหรับการรู้จำตัวเลขสามารถทำงานได้อย่างมีประสิทธิภาพและเหมาะสมสำหรับการใช้งานในระบบ AMR ภาคสนาม และเป็นองค์ประกอบสำคัญที่ช่วยเพิ่มความแม่นยำของระบบอ่านค่ามิเตอร์น้ำแบบอนาล็อกโดยรวม

5.4 Transition-State Handling Performance

เพื่อประเมินประสิทธิภาพของระบบในการจัดการกรณีตัวเลขอยู่ในสถานะกำลังเปลี่ยนค่า (digit rollover หรือ half-digit transition) งานวิจัยนี้ได้ทดสอบโมดูล Transition-State Handling ซึ่งประกอบด้วย การจำแนกสถานะของตัวเลข (transition vs. stable) และกลไก **pair + carry-over correction** โดยเฉพาะ เนื่องจากกรณีดังกล่าวเป็นแหล่งกำเนิดข้อผิดพลาดสำคัญของระบบ Automatic Meter Reading (AMR) แบบดั้งเดิม




Figure 12 Comparison of raw digit predictions and corrected digit values before and after applying the transition-state handling mechanism, illustrating improved continuity during digit rollover




Figure 13 ความต่อเนื่องของค่าตัวเลขตามลำดับเฟรม ก่อนและหลังการใช้ Transition-State Handling และกลไก carry-over correction

Figure 12 แสดงการเปรียบเทียบค่าตัวเลขจริง (ground truth) กับค่าที่ได้จากโมเดล CNN สำหรับการรู้จำตัวเลขเพียงอย่างเดียว โดยยังไม่ใช้กระบวนการจัดการ transition จะเห็นว่าแม้ค่าที่ทำนายได้จะมีแนวโน้มใกล้เคียงกับค่าจริงโดยรวม แต่ในช่วงที่ตัวเลขเกิดการ rollover ผลลัพธ์ยังคงมีลักษณะไม่ต่อเนื่องและเกิดการกระโดดของค่า ซึ่งสะท้อนข้อจำกัดของการรู้จำตัวเลขแบบแยกรายหลักโดยไม่พิจารณาบริบทเชิงลำดับของตัวเลข

เมื่อประยุกต์ใช้โมดูล Transition-State Handling ผลลัพธ์ที่ได้หลังการแก้ไขแสดงใน

Figure 13 ซึ่งเป็นกราฟความต่อเนื่องของค่าตัวเลขตามลำดับเฟรม (frame index) โดยเปรียบเทียบระหว่างค่าที่ได้ก่อนการแก้ไข (raw digit output) และค่าหลังการแก้ไขด้วยกลไก carry-over (corrected digit output) พบว่าค่าหลังการแก้ไขมีความต่อเนื่องและสอดคล้องกับกลไกการทำงานจริงของมิเตอร์น้ำแบบโรลเลอร์อย่างชัดเจน ลดความผันผวนของค่าที่อ่านได้ในช่วง transition ได้อย่างมีนัยสำคัญ

ผลการทดลองดังกล่าวชี้ให้เห็นว่า การผสาน **digit-wise CNN recognition** เข้ากับ **Transition-State Classification** และ **carry-over logic** ช่วยให้ระบบสามารถจัดการข้อผิดพลาดเฉพาะตำแหน่งได้โดยไม่กระทบค่าตัวเลขทั้งหมด ซึ่งเป็นข้อได้เปรียบเหนือระบบ AMR แบบดั้งเดิมที่มักล้มเหลวในกรณี half-digit transition โดยเฉพาะในข้อมูลภาพจากสภาพแวดล้อมจริง

โดยสรุป โมดูล Transition-State Handling มีบทบาทสำคัญในการเพิ่มความเสถียรและความน่าเชื่อถือของค่ามิเตอร์ที่อ่านได้ และเป็นองค์ประกอบหลักที่ช่วยให้ระบบสามารถรองรับการใช้งานในภาคสนามได้อย่างมีประสิทธิภาพเมื่อทำงานร่วมกับ Digit Module และ Pointer Module ในระดับระบบโดยรวม

5.5 Pointer Angle Regression Performance

ในส่วนนี้เป็นการประเมินประสิทธิภาพของโมดูลอ่านค่าหน้าปัดเข็ม (Pointer Module) ซึ่งมีหน้าที่ประมาณค่ามุมของเข็มบนหน้าปัดมิเตอร์น้ำแบบอนาล็อกจากภาพอินพุตจริง การประมาณค่ามุมอย่างแม่นยำถือเป็นขั้นตอนสำคัญในการแปลงข้อมูลเชิงเรขาคณิตให้เป็นค่าปริมาณการใช้น้ำที่ถูกต้อง

โมเดล Pointer Angle Regression ถูกฝึกด้วยชุดข้อมูลภาพหน้าปัดเข็มจำนวนมากกว่า 3,000 ภาพ โดยกำหนดค่า ground truth ของแต่ละภาพในรูปของฟังก์ชันตรีโกณมิติ ($\sin\theta$, $\cos\theta$) เพื่อหลีกเลี่ยงปัญหาความไม่ต่อเนื่องของมุมในช่วงเปลี่ยนรอบของเข็ม การฝึกดำเนินการเป็นเวลา 60 epochs โดยใช้ฟังก์ชันสูญเสียแบบ Mean Squared Error (MSE) และใช้ Adam optimizer เพื่อให้โมเดลสามารถเรียนรู้ความสัมพันธ์เชิงมุมได้อย่างเสถียร

ผลการประเมินจากชุดข้อมูลทดสอบแสดงให้เห็นว่าโมเดลสามารถทำนายมุมของเข็มได้อย่างแม่นยำ โดยมีค่า Mean Absolute Error (MAE) ประมาณ ± 3 องศา และมีความถูกต้องภายในช่วงความคลาดเคลื่อน ± 5 องศาสูงถึง 96% แสดงถึงความสามารถของโมเดลในการรับมือกับสภาพภาพจริงที่มีความท้าทาย เช่น แสงสะท้อนจากกระจกหน้าปัด ความเบลอ และมุมกล้องที่ต่างกัน

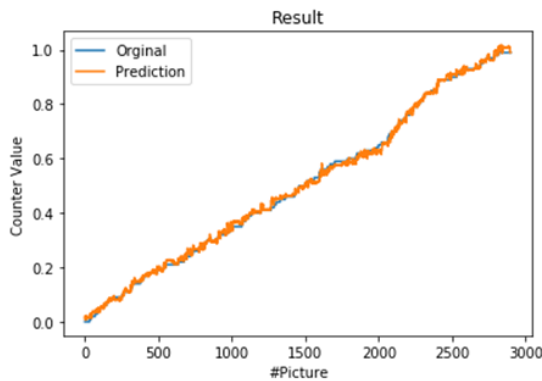


Figure 14 การเปรียบเทียบค่ามุมเข็มจริง (ground truth) กับค่ามุมที่โมเดล Pointer Angle Regression ทำนายได้ แสดงให้เห็นแนวโน้มที่สอดคล้องกันและความเสถียรของการประมาณค่ามุมตลอดช่วงข้อมูลทดสอบ

แสดงกราฟเปรียบเทียบระหว่างค่ามุมจริงของเข็ม (ground truth) และค่าที่โมเดลทำนายได้จาก Pointer Angle Regression ซึ่งพบว่าค่าที่ทำนายมีแนวโน้มสอดคล้องกับค่าจริงตลอดช่วงข้อมูล แสดงให้เห็นถึงความต่อเนื่องและความเสถียรของโมเดลในการประมาณค่ามุมเข็ม

โดยสรุป Pointer Angle Regression Module ที่นำเสนอสามารถประมาณค่ามุมของเข็มได้อย่างมีประสิทธิภาพ และสามารถนำไปใช้งานร่วมกับ Digit Module ได้อย่างเหมาะสม เพื่อรองรับการอ่านค่ามิเตอร์น้ำแบบอนาล็อกที่มีทั้งตัวเลขแบบโรลเลอร์และหน้าปัดเข็มในระบบเดียว ซึ่งเป็นจุดเด่นสำคัญของระบบ AMR ที่พัฒนาในงานวิจัยนี้

5.6 System-Level Evaluation

การประเมินผลในระดับระบบ (system-level evaluation) มีวัตถุประสงค์เพื่อวัดประสิทธิภาพของระบบอ่านค่ามิเตอร์น้ำแบบครบวงจร (end-to-end) หลังจากผสานผลลัพธ์จากทุกโมดูล ได้แก่ YOLO-Based ROI Detection, Digit Module (CNN + Transition Model) และ Pointer Module (Pointer Angle Regression) เข้าด้วยกันผ่านขั้นตอน Sanity Validation and Fusion

การประเมินในระดับนี้มุ่งเน้นความถูกต้องของค่ามิเตอร์สุดท้าย (final meter reading) ซึ่งเป็นผลลัพธ์ที่ผู้ใช้งานหรือระบบ AMR นำไปใช้งานจริง โดยพิจารณาความสอดคล้องระหว่างค่าที่ระบบคำนวณได้กับค่าอ้างอิงจริง (ground truth) จากข้อมูลภาคสนาม

ผลการทดลองแสดงให้เห็นว่า การผสานผลลัพธ์จาก Digit Module และ Pointer Module ช่วยลดข้อผิดพลาดที่เกิดจากการอ่านค่าจากแหล่งข้อมูลเพียงประเภทเดียวได้อย่างมีประสิทธิภาพ โดยเฉพาะในกรณีนี้

- ตัวเลขแบบโรลเลอร์อยู่ในสถานะก้ำกึ่ง (digit rollover),
- ค่าทศนิยมจากหน้าปัดเข็มอยู่ใกล้จุดเปลี่ยนรอบ,
- หรือภาพมีสัญญาณรบกวนจากแสงสะท้อนและมุมกล้อง

กลไก Sanity Validation ทำหน้าที่ตรวจสอบความสมเหตุสมผลของค่าที่ได้ เช่น ความต่อเนื่องของค่ามิเตอร์เมื่อเทียบกับค่าก่อนหน้า และความสอดคล้องระหว่างค่าจำนวนเต็มจาก Digit Module กับค่าทศนิยมจาก Pointer Module ขณะที่ขั้นตอน Fusion ทำหน้าที่รวมข้อมูลจากทั้งสองแหล่งให้เป็นค่ามิเตอร์สุดท้ายที่มีความเสถียรและเชื่อถือได้

ผลการประเมินในระดับระบบพบว่า ระบบสามารถอ่านค่ามิเตอร์น้ำได้อย่างถูกต้องในภาพส่วนใหญ่ของชุดทดสอบ โดยมีค่า **Final Meter Reading Accuracy** อยู่ในระดับสูง แสดงให้เห็นว่าการออกแบบระบบแบบ multi-module และการจัดการ transition อย่างเป็นระบบช่วยเพิ่มความแม่นยำโดยรวม เมื่อเทียบกับระบบ AMR แบบดั้งเดิมที่พึ่งพาการอ่านค่าจากโมดูลเดียว

โดยสรุป ผลการประเมินในระดับระบบยืนยันว่าระบบที่นำเสนอสามารถทำงานได้อย่างมีประสิทธิภาพในสภาพแวดล้อมจริง รองรับมิเตอร์น้ำอนาล็อกที่มีทั้งตัวเลขแบบโรลเลอร์และหน้าปัดเข็ม และมีศักยภาพในการนำไปประยุกต์ใช้ในระบบ AMR ภาคสนามได้อย่างเป็นรูปธรรม

6. Discussion

งานวิจัยนี้นำเสนอระบบอ่านค่ามิเตอร์น้ำแบบอนาล็อกที่ผสานเทคนิค Deep Learning หลายโมดูลเข้าด้วยกัน เพื่อจัดการกับข้อจำกัดที่พบได้จริงในงาน Automatic Meter Reading (AMR) ภาคสนาม ผลการทดลองใน Section 5 แสดงให้เห็นว่าการออกแบบระบบแบบแยกโมดูล (modular design) และการประเมินผลในหลายระดับมีบทบาทสำคัญในการเพิ่มความแม่นยำและความเสถียรของระบบโดยรวม

6.1 Effectiveness of Multi-Stage ROI Detection

ผลการทดลองของ YOLO-Based ROI Detection แสดงให้เห็นว่าการแยกตรวจจับบริเวณที่เกี่ยวข้องออกเป็นหลายประเภท ได้แก่ ช่องตัวเลข (digit window), หน้าปัดเข็ม (pointer dial) และ ตำแหน่งปลายเข็ม (pointer tip) ช่วยลดความซับซ้อนของขั้นตอนถัดไปได้อย่างมีนัยสำคัญ การตรวจจับ ROI ที่แม่นยำช่วยจำกัดพื้นที่ประมวลผลให้เฉพาะบริเวณที่จำเป็น ส่งผลให้ทั้ง Digit Module และ Pointer Module สามารถทำงานได้อย่างมีประสิทธิภาพ แม้ในสภาพแวดล้อมที่มีแสงสะท้อนหรือฉากหลังรบกวน

6.2 Advantages of Digit-Wise Recognition over Sequence-Based OCR

การรู้จำตัวเลขแบบ digit-wise ด้วย CNN แสดงให้เห็นถึงความยืดหยุ่นที่เหนือกว่าวิธีการรู้จำแบบลำดับ (sequence-based OCR) โดยเฉพาะในกรณีที่การครอบภาพมีความคลาดเคลื่อนเล็กน้อยหรือรูปแบบตัวเลขไม่สม่ำเสมอ ผลการทดลองยืนยันว่าข้อผิดพลาดที่เกิดขึ้นในตำแหน่งใดตำแหน่งหนึ่งไม่ส่งผลกระทบต่อค่าทั้งหมด ซึ่งเป็นข้อได้เปรียบสำคัญสำหรับการใช้งานจริงในระบบ AMR

อย่างไรก็ตาม ข้อจำกัดที่ยังพบได้คือกรณีตัวเลขอยู่ในสถานะก้ำกึ่งระหว่างการเปลี่ยนค่า (digit rollover) ซึ่งเป็นลักษณะเฉพาะของมิเตอร์น้ำแบบโรลเลอร์ และไม่สามารถแก้ไขได้ด้วย CNN เพียงอย่างเดียว

6.3 Importance of Transition-State Handling

ผลการทดลองใน Section 5.4 แสดงให้เห็นอย่างชัดเจนว่า Transition-State Classification และกลไก pair + carry-over มีบทบาทสำคัญในการแก้ปัญหา half-digit transition การเปรียบเทียบผลลัพธ์ก่อนและหลังการจัดการ transition แสดงให้เห็นว่าค่าที่ได้หลังการแก้ปัญหามีความต่อเนื่องและสอดคล้องกับกลไกการทำงานจริงของมิเตอร์น้ำมากขึ้น ซึ่งช่วยลดความผันผวนของค่าที่อ่านได้ในลำดับภาพต่อเนื่อง

แนวทางนี้แตกต่างจากงาน AMR แบบดั้งเดิมที่มักมองการรู้จำตัวเลขเป็นปัญหาเชิงภาพเพียงอย่างเดียว โดยไม่พิจารณาบริบทเชิงกลไกของอุปกรณ์วัดค่า

6.4 Robustness of Pointer Angle Regression

Pointer Angle Regression ที่ใช้การแทนค่ามุมในรูปแบบ $(\sin\theta, \cos\theta)$ ช่วยให้โมเดลสามารถเรียนรู้เชิงมุมได้อย่างต่อเนื่อง และลดปัญหาความไม่ต่อเนื่องบริเวณจุดเปลี่ยนรอบของเข็ม ผลการประเมินแสดงให้เห็นว่าโมเดลสามารถทำนายมุมเข็มได้อย่างแม่นยำและมีเสถียรภาพ แม้ในกรณีที่เข็มมีลักษณะบางหรือมีแสงสะท้อนจากกระจกหน้าปัด

เมื่อผสานผลลัพธ์ของ Pointer Module เข้ากับ Digit Module ผ่านขั้นตอน Fusion พบว่าสามารถเพิ่มความถูกต้องของค่ามิเตอร์สุดท้ายได้ โดยเฉพาะในช่วงค่าทศนิยมที่มีความละเอียดสูง

6.5 System-Level Implications and Practical Deployment

ผลการประเมินในระดับระบบยืนยันว่าการผสานหลายโมดูลเข้าด้วยกันช่วยเพิ่มความแม่นยำของระบบอ่านค่ามิเตอร์น้ำแบบอนาล็อกได้อย่างมีนัยสำคัญ เมื่อเทียบกับระบบที่พึ่งพาโมเดลเดี่ยวเพียงประเภทเดียว ระบบที่นำเสนอสามารถรองรับความหลากหลายของรูปแบบมิเตอร์ สภาพแสง และมุมกล้องได้ดี ซึ่งเป็นปัจจัยสำคัญสำหรับการนำไปใช้งานจริงในภาคสนาม

อย่างไรก็ตาม ระบบยังมีข้อจำกัดในกรณีที่ภาพมีความเบลอสูงหรือการบังบางส่วนของตัวเลขและเข็ม ซึ่งอาจต้องอาศัยข้อมูลลำดับเวลาหรือข้อมูลจากหลายเฟรมเพิ่มเติมในอนาคต

6.6 Summary of Discussion

โดยสรุป งานวิจัยนี้แสดงให้เห็นว่าการออกแบบระบบ AMR แบบ multi-module ที่ผสานการรู้จำเชิงภาพเข้ากับความรู้เชิงกลไกของมิเตอร์น้ำ สามารถลดข้อผิดพลาดที่พบได้จริงในงานภาคสนาม และเพิ่มความเชื่อถือได้ของค่าที่อ่านได้อย่างมีนัยสำคัญ ผลลัพธ์ที่ได้สนับสนุนศักยภาพของระบบในการนำไปประยุกต์ใช้ในงาน AMR จริง และเป็นแนวทางที่สามารถขยายผลไปยังอุปกรณ์วัดค่าแบบอนาล็อกประเภทอื่นได้ในอนาคต

7. Conclusion & Future Work

7.1 Conclusion

งานวิจัยนี้ได้นำเสนอระบบอ่านค่ามิเตอร์น้ำแบบอนาล็อก (Automatic Meter Reading: AMR) ที่ออกแบบในลักษณะโมดูล โดยผสานเทคนิค Deep Learning หลายส่วนเข้าด้วยกัน

เพื่อแก้ไขข้อจำกัดของการอ่านค่ามิเตอร์ในสภาพแวดล้อมภาคสนามจริง ระบบประกอบด้วย YOLO-Based ROI Detection สำหรับการตรวจจับบริเวณสำคัญของมิเตอร์, Digit Module สำหรับการรู้จำตัวเลขแบบโรลเลอร์ (roller-type digits), Pointer Module สำหรับการประมาณมุมเข็ม และขั้นตอน Sanity Validation and Fusion สำหรับการผสานผลลัพธ์ในระดับระบบ

ผลการทดลองแสดงให้เห็นว่าโมเดล YOLO สามารถตรวจจับบริเวณที่เกี่ยวข้องได้อย่างแม่นยำ โดยมีค่า precision, recall และ mAP อยู่ในระดับสูง ขณะที่ Digit Module แบบ digit-wise CNN ให้ความแม่นยำในการรู้จำตัวเลขหลักได้ดี และเมื่อผสานกับ Transition-State Classification และกลไก pair + carry-over สามารถลดข้อผิดพลาดที่เกิดจากกรณี half-digit transition ได้อย่างมีนัยสำคัญ

สำหรับการอ่านค่าจากหน้าปัดเข็ม โมเดล Pointer Angle Regression สามารถประมาณมุมเข็มได้อย่างเสถียร โดยมีค่า Mean Absolute Error (MAE) อยู่ในระดับต่ำ และให้ความแม่นยำสูงเมื่อแปลงเป็นค่าปริมาณการใช้ น้ำ เมื่อพิจารณาผลลัพธ์ในระดับระบบ (system-level evaluation) ระบบที่นำเสนอสามารถอ่านค่ามิเตอร์น้ำได้อย่างถูกต้องและมีความต่อเนื่องในลำดับภาพ (sequential images) ซึ่งสะท้อนถึงความพร้อมในการนำไปประยุกต์ใช้งานจริงในสภาพภาคสนาม

โดยสรุป งานวิจัยนี้แสดงให้เห็นว่าการออกแบบระบบ AMR แบบโมดูลาร์ที่ผสมผสานการรู้จำตัวเลข การจัดการช่วง transition และการอ่านค่าจากเข็มชี้ สามารถเพิ่มความแม่นยำ ความทนทาน และความน่าเชื่อถือของระบบอ่านค่ามิเตอร์น้ำแบบอนาล็อกได้อย่างมีประสิทธิภาพ เมื่อเทียบกับแนวทาง OCR หรือระบบอ่านค่าแบบดั้งเดิม

7.2 Future Work

แม้ว่าระบบที่นำเสนอจะให้ผลลัพธ์ที่น่าพอใจ แต่ยังมีแนวทางในการพัฒนาต่อยอดในอนาคตเพื่อเพิ่มความสามารถของระบบให้ครอบคลุมการใช้งานจริงมากยิ่งขึ้น ประเด็นแรกคือการขยายและเพิ่มความหลากหลายของชุดข้อมูลฝึก โดยเฉพาะภาพจากสภาพแวดล้อมภาคสนามที่ท้าทาย เช่น สภาพแสงน้อย การสะท้อนจากกระจก น้ำเกาะบนหน้าปัด หรือมิเตอร์ที่มีการลึกลง ซึ่งจะช่วยเพิ่มความสามารถในการ generalize ของโมเดล

นอกจากนี้ ระบบสามารถพัฒนาไปสู่การใช้ข้อมูลเชิงเวลา (temporal information) จากภาพต่อเนื่องหรือวิดีโอ เพื่อเรียนรู้

พฤติกรรมการเปลี่ยนค่าของตัวเลขและตำแหน่งเข็มในระยะยาว โดยอาจประยุกต์ใช้โมเดลเชิงลำดับที่มีความซับซ้อนมากขึ้น เช่น temporal deep learning หรือ sequence-based modeling ซึ่งจะช่วยลดการพึ่งพาการตรวจจับเฟรม และเพิ่มความยืดหยุ่นของระบบในสภาพการใช้งานจริง